

NTIC/TLSI



**Master 1: SDSI**

Module : Business Intelligence Avancée

## RAPPORT DE PROJET

### *Analyse Décisionnelle des Ventes dans les Centres Commerciaux*

**Etudiants :** Mohamed Redouane Haddad

Hanchi Takoua Belkis

Guenifi Djoumana

Boudersa Kaouther

**Date:** 03 / 05 / 2026

## **1.Introduction**

Dans un environnement économique de plus en plus compétitif, les entreprises commerciales cherchent

à exploiter leurs données transactionnelles pour prendre des décisions stratégiques éclairées. Ce projet

s'inscrit dans le cadre du module Business Intelligence & Analyse de Données et vise à concevoir et réaliser une application décisionnelle complète basée sur des données réelles de transactions dans des centres

commerciaux en Turquie.

Le dataset couvre 99 457 transactions entre janvier 2021 et mars 2023 dans 10 centres commerciaux

d'Istanbul, disponible publiquement sur Kaggle .

## **2.Étude fonctionnelle**

### **Description du besoin décisionnel**

Les responsables commerciaux et analystes métier ont besoin de réponses à des questions stratégiques :

- Quelles catégories de produits génèrent le plus de chiffre d'affaires ?
- Quels centres commerciaux sont les plus performants en termes de revenus ?
- Comment évolue le CA au fil du temps (tendances mensuelles, saisonnalité) ?
- Quel est le profil démographique des clients (genre, tranche d'âge) ?
- Y a-t-il des différences de comportement d'achat selon le genre ou l'âge ?

## Identification des utilisateurs (décideurs, analystes...)

| Profil                | Rôle     | Besoins                                                      |
|-----------------------|----------|--------------------------------------------------------------|
| Directeur commercial  | Décideur | Suivi du CA global, comparaison des performances entre malls |
| Responsable marketing | Décideur | Analyse des profils clients, segmentation par genre et âge   |
| Analyste de données   | Analyste | Exploration détaillée, filtres croisés, analyse temporelle   |
| Responsable de mall   | Décideur | Performance de son centre, catégories dominantes             |

## 3.Modélisation

### Schéma conceptuel du Data Warehouse

Le schéma adopté pour ce projet est un **schéma en étoile** (star schema) Ce choix est motivé par :

- La simplicité des requêtes analytiques qu'il permet
- Sa compatibilité native avec Microsoft Power BI
- Ses bonnes performances pour des volumes de données moyens ( 100K lignes)
- La facilité de compréhension pour les utilisateurs non-techniques

### Faits et dimensions identifiés

| Table        | Type      | Colonnes principales                                                                                 |
|--------------|-----------|------------------------------------------------------------------------------------------------------|
| Fact_Sales   | Faits     | invoice_no (dim. dégénérée), customer_id, category_id, payment_id, date_id, mall_id, quantity, price |
| Dim_Client   | Dimension | customer_id (PK), gender, age, Age_Group                                                             |
| Dim_Date     | Dimension | date_id (PK), invoice_date, day, month, quarter, year                                                |
| Dim_Category | Dimension | category_id (PK), category_name                                                                      |
| Dim_Payment  | Dimension | payment_id (PK), payment_method                                                                      |
| Dim_Location | Dimension | mall_id (PK), mall_name                                                                              |

### Modèle logique (tables, relations, clés)

**sales**(invoice\_no,customer\_id\*,category\_id\*,payment\_id\*,date\_id\*,mall\_id\*,quantity, price,total\_revenue,total\_transactions)

**client**(customer\_id, age, age\_group, gender)

**category**(category\_id, category\_name)

**payment**(payment\_id, payment\_method)


**date**(date\_id, invoice\_date, day, month, quarter, year)

**location**(mall\_id, mall\_name)

### **Justification du choix de modèle :**

Nous avons choisi un **modèle en étoile** car il est simple à mettre en œuvre et bien adapté à l'analyse décisionnelle.

**Le niveau de granularité** est la transaction de vente, ce qui permet de suivre chaque opération effectuée par un client dans un centre commercial. Ce niveau offre un degré de détail suffisant pour analyser les quantités vendues, les revenus générés, les catégories de produits, les modes de paiement ainsi que les périodes de vente. **L'historisation** n'est pas nécessaire, car les données de vente sont considérées comme figées une fois la transaction enregistrée.



- **Intégration des données (ETL)**
  - Sources de données utilisées (fictives ou réelles)

| Attribut        | Détail                            |
|-----------------|-----------------------------------|
| Dataset         | Customer Shopping Dataset         |
| Plateforme      | Kaggle.com                        |
| Format          | CSV (Comma-Separated Values)      |
| Volume          | 99 457 lignes, 10 colonnes        |
| Période         | Janvier 2021 – Mars 2023          |
| Nombre de malls | 10 centres commerciaux – Istanbul |

- Outils et technologies utilisés (ex. PowerBI, Talend, Python...)

| Outil                           | Usage                                              |
|---------------------------------|----------------------------------------------------|
| Microsoft Power BI Desktop      | Outil principal ETL, modélisation et visualisation |
| Power Query (M Language)        | Transformation et nettoyage des données            |
| DAX (Data Analysis Expressions) | Création des mesures calculées                     |
| Power BI Service                | Publication et automatisation des rapports         |

- Description des étapes ETL :

- **Extraction**

Le fichier CSV a été importé dans Power BI Desktop via Accueil › Obtenir des données › Texte/CSV.

L'option Transformer les données a été choisie pour ouvrir l'éditeur Power Query avant le chargement

final, permettant d'effectuer toutes les transformations nécessaires en amont

- **Transformation**

- Nettoyage : Activation de la vue Qualité des colonnes pour détecter valeurs nulles et erreurs. Correction

des types : age et quantity en entier, price en décimal, invoice\_date en date.

- Reconstruction de la date : La colonne invoice\_date (format texte M/D/YYYY) a été décomposée en

day, month, year puis reconstruite en date valide via une colonne personnalisée en langage M.

- Création des dimensions : Chaque table créée par duplication de la requête source, suppression des

doublons et ajout d'un index comme clé de substitution. Colonne Age\_Group ajoutée à Dim\_Client (tranches 18-24, 25-34, 35-44, 45-54, 55+).

- Création de Fact\_Sales : Table construite par fusion (Left Outer Join) avec chaque dimension pour substituer les valeurs textuelles par les FK numériques.

- **Chargement**

Après validation, les 6 tables ont été chargées dans le modèle interne Power BI via Fermer et appliquer.

Les relations Many-to-One entre chaque FK de Fact\_Sales et la PK de la dimension correspondante ont été

configurées manuellement dans la vue Modèle.


## 4. Analyse et visualisation


### Mesures DAX créées

| Mesure                | Formule DAX                                                                                               |
|-----------------------|-----------------------------------------------------------------------------------------------------------|
| Total Revenue         | $\text{SUMX}(\text{Fact\_Sales}, \text{Fact\_Sales}[\text{quantity}] * \text{Fact\_Sales}[\text{price}])$ |
| Total Transactions    | $\text{COUNTROWS}(\text{Fact\_Sales})$                                                                    |
| Total Quantity        | $\text{SUM}(\text{Fact\_Sales}[\text{quantity}])$                                                         |
| Avg Transaction Value | $\text{DIVIDE}([\text{Total Revenue}], [\text{Total Transactions}])$                                      |
| Avg Customer Age      | $\text{AVERAGE}(\text{Dim\_Client}[\text{age}])$                                                          |

### Tableaux de bord créés

Le projet comprend deux pages de tableau de bord interactif dans Power BI. Des slicers permettent de filtrer dynamiquement par année, catégorie, genre, centre commercial et mode de paiement.





Page 2

## Interprétation des résultats et apports pour la prise de décision

- Catégorie dominante : La Clothing est la catégorie la plus rentable avec 114M de revenus, suivie des

chaussures (67M) et de la technologie (58M). Ces trois catégories doivent concentrer les efforts marketing.

- Performance des malls : Mall of Istanbul et Kanyon sont les deux centres les plus performants. Leurs

pratiques peuvent servir de modèle pour les centres moins performants.

- Mode de paiement : La carte de crédit est le mode dominant (44.69%), suggérant une clientèle à fort

pouvoir d'achat. Le paiement en espèces représente 35.12%.

- Profil client : Les femmes représentent 59.81% des transactions. Les clients de 55 ans et plus génèrent le

plus de revenus (72M), contrairement aux idées reçues.

- Tendance temporelle : Le CA mensuel est stable entre 8M et 11M sur 2021-2022. La chute de janvier

2023 reflète une incomplétude des données source, et non une baisse réelle des ventes.

## 5.Aspects avancés


- Analyse predictive



Une analyse prédictive a été intégrée dans Power BI via la fonctionnalité de prévision (Forecast) disponible dans l'onglet Analytique des visuels de type courbe.

| Paramètre               | Valeur                                           |
|-------------------------|--------------------------------------------------|
| Outil                   | Power BI Analytics – Forecast                    |
| Longueur de prévision   | 3 mois                                           |
| Intervalle de confiance | 95%                                              |
| Variable prédite        | Chiffre d'affaires mensuel total (Total Revenue) |
| Algorithme              | Lissage exponentiel (intégré Power BI)           |

La zone ombrée (rose) sur le graphique temporel représente l'intervalle de confiance à 95%, indiquant la plage dans laquelle le CA devrait se situer avec une probabilité de 95%.



### Automatisation de processus BI

Une subscription automatique a été configurée sur Power BI Service pour envoyer le tableau de bord par email aux destinataires concernés selon un planning défini.

| Paramètre     | Configuration                                                 |
|---------------|---------------------------------------------------------------|
| Nom           | Rapport BI – Analyse des ventes                               |
| Fréquence     | Quotidienne                                                   |
| Heure d'envoi | 10h00 AM (UTC)                                                |
| Date de début | 26 Avril 2026                                                 |
| Destinataires | Équipe projet + encadrant                                     |
| Objet email   | Rapport BI – Analyse des ventes   Customer Shopping Dashboard |

## 6.Conclusion

### Bilan du projet

Ce projet a permis de concevoir et réaliser une application décisionnelle complète, couvrant l'ensemble du

cycle de vie d'un projet BI. Les objectifs initiaux ont été atteints :

- Un entrepôt de données structuré en schéma étoile avec 5 dimensions et une table de faits
- Un processus ETL complet réalisé avec Power Query
- Deux tableaux de bord interactifs offrant des analyses multidimensionnelles
- Une analyse prédictive par prévision temporelle (lissage exponentiel, IC 95%)
- Une automatisation de la diffusion des rapports via Power BI Service

### Apports du projet par rapport au module

- La modélisation dimensionnelle : schéma en étoile, faits, dimensions, granularité
- Le processus ETL complet : extraction, transformation, chargement
- Les opérations OLAP : drill-down, slice, dice via les slicers et hiérarchies
- La visualisation et le reporting décisionnel

### Limites du travail réalisé

- Dataset incomplet : les données 2023 couvrent uniquement janvier-mars, limitant l'analyse temporelle

et la qualité des prévisions

- Absence de données produit détaillées (marque, taille, couleur), limitant la granularité par produit
- Pas d'historisation (SCD) : le modèle ne gère pas les Slowly Changing Dimensions

- Données géographiques limitées à une seule ville (Istanbul)

## Perspectives d'amélioration

- Intégration d'un dataset plus récent couvrant plusieurs années et plusieurs villes
- Mise en place de Slowly Changing Dimensions (SCD Type 2) pour historiser les attributs clients
- Développement d'un modèle ML pour la segmentation client (clustering) et la prédiction CLV
- Migration vers une architecture Data Warehouse cloud (Azure Synapse Analytics, Google BigQuery)
- Ajout d'alertes automatiques déclenchées sur seuils de CA

## Annexes

- Captures d'écran

| invoice_no | customer_id | quantity | price  | category_id | payment_id | mail_id | date_id |
|------------|-------------|----------|--------|-------------|------------|---------|---------|
| 1157775    | C331761     | 1        | 300,08 | 1           | 3          | 1       | 107     |
| 1624164    | C102685     | 1        | 300,08 | 1           | 3          | 1       | 160     |
| 1281274    | C130479     | 1        | 300,08 | 1           | 3          | 1       | 249     |
| 1115679    | C266462     | 1        | 300,08 | 1           | 3          | 1       | 259     |
| 1127930    | C576719     | 1        | 300,08 | 1           | 3          | 1       | 281     |
| 1208491    | C299172     | 1        | 300,08 | 1           | 3          | 1       | 355     |
| 1248770    | C646756     | 1        | 300,08 | 1           | 3          | 1       | 436     |
| 1238472    | C299327     | 1        | 300,08 | 1           | 3          | 1       | 598     |
| 1885734    | C105423     | 1        | 300,08 | 1           | 3          | 1       | 24      |
| 1970588    | C232031     | 1        | 300,08 | 1           | 3          | 1       | 437     |
| 1796389    | C244694     | 1        | 300,08 | 1           | 3          | 1       | 375     |
| 1304830    | C240135     | 1        | 300,08 | 1           | 3          | 1       | 305     |
| 1487727    | C162965     | 1        | 300,08 | 1           | 3          | 1       | 99      |
| 1517431    | C191174     | 1        | 300,08 | 1           | 3          | 1       | 422     |
| 1125822    | C120825     | 1        | 300,08 | 1           | 3          | 1       | 302     |
| 1153137    | C121391     | 1        | 300,08 | 1           | 3          | 1       | 17      |
| 1144724    | C138545     | 1        | 300,08 | 1           | 3          | 1       | 376     |
| 1955408    | C274639     | 1        | 300,08 | 1           | 3          | 1       | 748     |
| 1827306    | C271752     | 1        | 300,08 | 1           | 3          | 1       | 128     |

## Dim\_Category

```
let
    Source = customer_shopping_data,
    KeepCols = Table.SelectColumns(Source, {"category"}),
    Removed = Table.Distinct(KeepCols),
    AddIndex = Table.AddIndexColumn(Removed, "category_id", 1, 1, Int64.Type),
    Renamed = Table.RenameColumns(AddIndex, {"category", "category_name"}),
    Reordered = Table.ReorderColumns(Renamed, {"category_id", "category_name"})
in Reordered
```

## Dim\_Date

```

let
    Source      = customer_shopping_data,
    KeepCols    = Table.SelectColumns(Source, {"invoice_date","day","month","year"}),
    Removed     = Table.Distinct(KeepCols),
    AddQuarter  = Table.AddColumn(Removed, "quarter", each
        if [month] <= 3 then 1 else if [month] <= 6 then 2
        else if [month] <= 9 then 3 else 4, Int64.Type),
    AddIndex    = Table.AddIndexColumn(AddQuarter, "date_id", 1, 1, Int64.Type),
    Reordered   = Table.ReorderColumns(AddIndex,
        {"date_id","invoice_date","day","month","quarter","year"})
in Reordered

```

## Reconstruction de invoice\_date

```

Date.FromText(
    Text.From([year]) & "-" &
    Text.PadStart(Text.From([month]), 2, "0") & "-" &
    Text.PadStart(Text.From([day]), 2, "0")
)

```

- Exemples de requêtes SQL utilisées

```

// Chiffre d'affaires total
Total Revenue =
    SUMX(Fact_Sales, Fact_Sales[quantity] * Fact_Sales[price])

// Nombre de transactions
Total Transactions = COUNTROWS(Fact_Sales)

// Quantité totale vendue
Total Quantity = SUM(Fact_Sales[quantity])

// Valeur moyenne par transaction
Avg Transaction Value =
    DIVIDE([Total Revenue], [Total Transactions])

// Âge moyen des clients
Avg Customer Age = AVERAGE(Dim_Client[age])

```